

VAE de datasets completos

Guía de estudio · Preparación para la exposición

RESUMEN

Modelo generativo que aprende la distribución de datasets completos.

Dado un dataset real, genera sintéticos con la misma estructura de correlación y el número de muestras que el usuario elija.

0.0137

MAE_rA N=1000

98.5%

2-grupos cond.

0.9995

Predictor r

7.8×

KNN ratio

≈ 0

Error modelo

ÍNDICE

- 1 Motivación — el problema y la solución
- 2 Los datos de entrenamiento
- 3 Arquitectura — vec_resumen, encoder, decoder, copula
- 4 Función de pérdida y entrenamiento
- 5 Prueba 0 y 1 — Reconstrucción y fidelidad
- 6 Prueba 2 y 3 — Diversidad y N independiente
- 7 Prueba 4 — El espacio latente organizado
- 8 Prueba 5 — Datasets sin estructura 2-grupos
- 9 Prueba 6 — Límite físico del error
- 10 Distribución completa del error
- 11 Conclusiones, limitaciones y próximos pasos

Motivación — el problema y la solución

¿Cuál es el problema?

- Los generadores actuales (CTGAN, TVAE) generan fila a fila.
- La estructura global de correlaciones emerge por accidente, sin control.
- No puedes pedir "correlación intra-grupo = 0.50" y obtenerlo garantizado.

¿Cuál es la solución?

- Tratar el dataset completo (200 pacientes) como una sola unidad.
- Un punto $z \in \mathbb{R}^{64}$ representa la estructura estadística de un dataset entero.
- Dado un dataset real, el modelo genera sintéticos con la misma estructura.
- N_{out} es libre — puedes pedir 1000 muestras aunque el original tenga 50.





Figura 1 — Comparación de enfoques

NÚMEROS CLAVE			
• Unidad (actual)	Fila — 1 paciente	• Unidad (TDVAE)	Dataset — 200 pac.
• Control correlaciones	Explícito ✓	• N_{out} flexible	Sí — indep. de N_{in}

» PARA LA EXPOSICIÓN

"Los generadores actuales no controlan la estructura global.


TDVAE trata el dataset como una imagen: un punto en el latente

= una estructura estadística entera."

Los datos de entrenamiento

7000 datasets RNA-seq sintéticos · 200 muestras × 50 genes · 2 grupos

- 7000 datasets generados con Gaussian Copula y distribución marginal NegBinomial.
- Estructura de 2 grupos: genes 0-24 (Grupo A) y genes 25-49 (Grupo B).
- Cada dataset tiene correlación intra-grupo (r_A , r_B) e inter-grupo (cross) distintas.
- Partición: 5600 entrenamiento / 1400 test — el test nunca se usa en entrenamiento.



Nota sobre el benchmark:

- SHUFFLE_FRAC=0.20: hasta el 20% de genes se intercambian entre grupos por dataset.
- Más ruido gaussiano en la matriz de correlación → valores empíricos ≠ parámetros.
- Resultado: ~22% del test tiene $r_A \approx$ cross (estructura 2-grupos débil o ausente).
- El modelo aprende correctamente esta distribución, incluyendo los casos sin estructura.

NÚMEROS CLAVE			
• Total datasets	7000 (5600 train / 1400 test)	• Dimensiones	200 × 50 (muestras × genes)
• r_A rango empírico	[0.18, 0.69]	• cross rango empírico	[0.00, 0.51]
• Con 2-grupos	~78% del test	• Sin 2-grupos	~22% (casos límite benchmark)

» PARA LA EXPOSICIÓN

"Entrenamos con 7000 datasets distintos — cada uno es un ejemplo de entrenamiento.
El modelo aprende la distribución de estructuras de correlación, no de muestras."

Arquitectura del modelo

Encoder · Decoder con ResBlocks · Copula empírica · Predictor auxiliar




Figura 3 — Pipeline completo de TDVAE

► **Preprocesamiento:**

log1p + z-score/gen. Reduce asimetría NegBinomial.

► **vec_resumen (1375):**

corr upper_tri [1225] + μ/σ /skew por gen [150].

► **Encoder 1375→64:**

1375→1024→512→128 · LayerNorm+GELU · produce $\mu, \log\sigma$.

► **Espacio latente $\mathbb{R}^{64}$:**

$z = \mu + \epsilon \cdot \sigma \cdot \epsilon \sim N(0, I) \cdot \text{FREE_BITS} = 0.3/\text{dim}$.

► **Decoder 64→1375:**

64→ResBlocks×4→1375. Reconstruye el vec_resumen.

► **Copula empírica:**

N_out muestras con marginal real del input.

NÚMEROS CLAVE			
● Parámetros	4.299.810	● Latent dim	64
● Épocas / KL	800 · annealing 0→1 en 150 épocas	● Decoder target	vec_resumen (1375 dims)

» **PARA LA EXPOSICIÓN**


"El decoder reconstruye el resumen estadístico, no los datos crudos.
Esto hace que la loss compare estructuras de correlación, no valores ruidosos.
La Copula genera las muestras finales con N_out libre."

El vector resumen y la función de pérdida

Por qué no datos crudos · Loss sobre estructura, no sobre muestras

¿Por qué no dar el dataset crudo (10.000 valores) al encoder?

- Error estándar de la correlación de Pearson: $SE \approx 1/\sqrt{N-3} = 0.071$ con $N=200$.
- Dos datasets con estructura distinta pueden parecer idénticos con N pequeño.
- El `vec_resumen` agrega sobre 200 muestras → cada valor es 14× más estable.



Composición del `vec_resumen`



$1225 + 50 + 50 + 50 = 1375 \text{ dims}$

→ 21× más compacto que el dataset crudo (10.000 valores)

Figura 4 — SE de la correlación (izq.) y composición del `vec_resumen` (der.)

Función de pérdida:

$L = 2 \cdot \text{MSE}(\text{corr}) + \text{MSE}(\text{stats}) + \lambda_{\text{KL}} \cdot \text{KL} + \lambda \cdot L_{\text{pred}}$

- **MSE correlaciones ×2** Las correlaciones son lo que evaluamos → más peso
- **MSE estadísticos ×1** Preservar medias, stds y skews por gen
- **KL (annealing 0→1)** Espacio latente continuo · free bits=0.3/dim
- **Predictor $\lambda=1.0$** Organiza z por correlaciones (solo entrenamiento)

NÚMEROS CLAVE			
• <code>vec_resumen</code>	1375 dims	• Compresión	10.000 → 1375 (21×)
• SE con N=200	0.071 (ruido irreducible)	• KL total mínimo	$64 \times 0.3 = 19.2$

» PARA LA EXPOSICIÓN

"Darle al modelo 10.000 valores ruidosos es como dar los ladrillos en lugar de los planos. El `vec_resumen` son los planos: 1375 estadísticos estables que capturan toda la estructura relevante."

Prueba 0 — Reconstrucción · Prueba 1 — Fidelidad

$\sigma=0$ reproduce el original · 1400 datasets test nunca vistos

- Prueba 0 ($\sigma=0$, $N_{out}=N_{in}$): el modelo es determinista. ¿Reproduce el original?
- Prueba 1 (test set completo, 1400 datasets): ¿generaliza a datos no vistos?
- Métrica: $MAE_{rA} = |rA_{real} - rA_{sintético}|$ y preservación de estructura 2-grupos.





Figura 5 — MAE de correlaciones vs N_{out} (izq.) y preservación 2-grupos (der.)

Interpretación de los resultados:

- $MAE_{rA}=0.010$ significa: si la correlación real es 0.50, la sintética está entre 0.49 y 0.51.
- A ojo humano las matrices de correlación real y sintética son indistinguibles.
- Condiciona (98.5%): solo cuenta datasets donde el original tiene 2-grupos — es la correcta.
- Incondiciona (~78%) incluye el 22% sin estructura, que el modelo reproduce fielmente.

NÚMEROS CLAVE			
• MAE_{rA} N=200	0.0224	• MAE_{rA} N=1000	0.0137
• 2-grupos cond. N=200	98.5%	• 2-grupos cond. N=1000	99.1%
• P0: $MAE<0.05$ (N=1000)	1398/200	• Test set	1400 nunca vistos

» PARA LA EXPOSICIÓN


"Con $N=1000$ el error es 0.010 — $\pm 1\%$ en correlación. El 98.5% de las veces preserva la estructura 2-grupos cuando el original la tiene."

Prueba 2 — Control de diversidad · Prueba 3 — N independiente

σ_scale controla la variedad · N_out libre de N_in

- Prueba 2: σ_scale añade ruido en el latente. $z = \mu + \sigma \cdot \epsilon$ con $\epsilon \sim N(0, I)$.
- Si el control es real, el MAE debe subir monótonicamente con σ .
- Prueba 3: con N_in pequeño el vec_resumen tiene más ruido → mayor error en z .

MAE sube con σ_scale
(control real y monótonico ✓)



Error sigue SE teórico
(modelo no añade error extra)




Figura 6 — Control de diversidad con σ_scale (izq.) y N_in independiente (der.)

Interpretación:

- $\sigma=0$: re-síntesis exacta · $\sigma=0.5$: variaciones plausibles (recomendado) · $\sigma=1$: alta diversidad.
- El MAE sube monótonicamente con σ → el control de diversidad es real y predecible.
- $N_in=50$ da MAE=0.028, $N_in=200$ da MAE=0.010: la diferencia es ruido del vec_resumen.
- El MAE siempre queda bajo el SE teórico → el modelo no añade error propio.

NÚMEROS CLAVE

- | | | | |
|--------------------------------------|--|---------------------------------------|--|
| • $\sigma=0.0$ re-síntesis | MAE $\approx$ 0.0224 (N=200) | • $\sigma=0.5$ recomendado | MAE $\approx$ 0.0325 (N=200) |
| • $N_in=50 \rightarrow N_out=1000$ | MAE = 0.0313 | • $N_in=200 \rightarrow N_out=1000$ | MAE = 0.0135 |

» PARA LA EXPOSICIÓN

"Con $\sigma=0$ obtienes una copia estadística exacta. Con $\sigma=0.5$ obtienes variaciones plausibles. Y puedes ampliar 50 muestras a 1000 — el error es solo ruido estadístico del input, no del modelo."

Prueba 4 — El espacio latente está organizado

PC1↔cross $r=-0.955$ · PC2↔rA $r=0.873$ · KNN ratio=7.8×

- Evidencia 1 — PCA: PC1 captura cross_corr ($r=-0.955$), PC2 captura rA ($r=0.873$).
- Evidencia 2 — KNN: vecinos en z son 7.8× más similares que pares aleatorios.
- Evidencia 3 — Predictor: $z \rightarrow [rA, rB, cross]$ con $r=0.9995$ para las tres métricas.




Figura 7 — PCA del latente coloreado por cross (izq.), por rA (cen.) y análisis KNN (der.)

¿Qué demuestra que el latente está organizado?

- Cada punto del scatter = un dataset. El color muestra que cross varía en PC1 y rA en PC2.
- Tres métricas (cross, rA, rB) quedan en tres ejes ortogonales — sin forzarlo.
- KNN: los 5 vecinos en z tienen 7.8× menos diferencia de estructura que pares aleatorios.
- Pearson $r=0.893$ entre distancia euclídea en z y diferencia de estructura.

NÚMEROS CLAVE			
PC1 ↔ cross_corr	r = -0.955	PC2 ↔ rA	r = 0.873
Predictor $z \rightarrow$ correlaciones	r = 0.9995 para rA, rB y cross	KNN ratio	7.8×

» PARA LA EXPOSICIÓN


"El latente no es una caja negra. Tiene semántica: PC1=cross, PC2=rA.
Los vecinos en z son 7.8× más parecidos que pares aleatorios.
La distancia en z predice con $r=0.89$ cuánto se parecen dos datasets."

Prueba 5 — Datasets sin estructura 2-grupos

El 22% del benchmark no tiene estructura 2-grupos en el original

- El 22% del test tiene $rA \approx \text{cross}$ en el dataset ORIGINAL (no en el sintético).
- Estos son casos límite del benchmark (SHUFFLE + ruido), no errores del modelo.
- El modelo los reproduce correctamente — no inventa estructura donde no la hay.

Fidelidad del margen
original → sintético (N=200)



Condicional: 98.9%




Figura 8 — Scatter margen real vs sintético (izq.) y categorías de preservación (der.)

¿Qué prueban estas figuras?

- Scatter: puntos sobre $y=x$ → el modelo reproduce fielmente el margen real ($rA-cross$).
- Incluye casos con margen negativo (sin estructura) — el modelo no los "arregla".
- Barras: 1216 preservan estructura, 13 la pierden, 157 sin estructura bien reproducidos.
- La métrica correcta es la condicional: 98.9% cuando el original tiene 2-grupos.

NÚMEROS CLAVE			
• Con estructura original	1229/1400 (88%)	• Preservan (condicional)	1216/1229 (98.9%)
• Sin estructura → OK	157/171 (92%)	• Métrica correcta	Condicional

» PARA LA EXPOSICIÓN


"La métrica incondicional (78%) confunde. La correcta es 98.9%:

cuando el original tiene estructura 2-grupos, el modelo la preserva.",

Prueba 6 — Límite físico · Distribución del error

El error del modelo es estadísticamente indistinguible de cero

- Si MAE sigue la curva $1/\sqrt{N}$ y está siempre debajo del SE teórico $\rightarrow$ error modelo ≈ 0 .
- La distribución del error muestra cuántos datasets tienen error en cada nivel.
- El error es independiente de la estructura del dataset ($r=0.105$).



Interpretación:

- El SE teórico es el ruido estadístico inevitable al muestrear N instancias con la Copula.
- $MAE < SE$ para todo N (con $N=2000$: $0.0128 < 0.0224$) $\rightarrow$ el modelo no añade error.
- 42% de datasets con $MAE < 0.01$ · 75% con $MAE < 0.02$ · 100% con $MAE < 0.05$.
- El error es independiente de la estructura del dataset (Pearson $r=0.105$).

NÚMEROS CLAVE			
• MAE $N=200$	0.0207 < SE 0.071	• MAE $N=1000$	0.0143 < SE 0.032
• MAE $N=2000$	0.0128 (suelo)	• % MAE < 0.01	42%
• % MAE < 0.02	75%	• Error vs estructura	$r=0.105$ (indep.)

» PARA LA EXPOSICIÓN

"El 42% de las veces el error es < 0.01 — invisible a ojo.
Con $N=2000$ el error del modelo puro es efectivamente cero."

Conclusiones, limitaciones y próximos pasos

Prueba	Qué demuestra	Resultado	Interpretación
P0. Reconstrucción	$\sigma=0$ reproduce el original	199/200 ✓	Reconstrucción casi perfecta
P1. Fidelidad	MAE en correlaciones	0.0137 N=1000	$\pm 1\%$ en correlación
P1. 2-grupos	Preservación condicional	98.5% N=200	Correcta cuando orig. la tiene
P2. Diversidad	σ_{scale} controla variedad	Monotónico ✓	Control real y predecible
P3. N independiente	N_out libre	MAE=0.0313 N_in=50	Ampliar datasets pequeños
P4. Latente	Organización semántica	KNN $7.8\times \cdot r=0.9995$	Mapa navegable
P5. Sin estructura	Reproduce casos sin 2-grupos	98.9% cond.	Aprende toda la distribución
P6. Error puro	MAE < SE teórico para todo N	Error modelo ≈ 0	Límite estadístico alcanzado

Tabla 1 — Resumen de todas las pruebas

Logros principales:

- MAE_rA = 0.0137 con N=1000 — prácticamente el límite estadístico.
- 2-grupos condicional: 98.5% con N=200.
- Espacio latente organizado: PC1↔cross, PC2↔rA, PC3↔rB. KNN ratio=7.8×.
- 75% de datasets con MAE<0.02. Error del modelo ≈ 0 .

Limitaciones honestas:

- Entrenado en 50 genes sintéticos — no evaluado en datos reales (TCGA, GEO).
- Solo estructura 2-grupos con correlación en bloques — no generaliza sin reentrenar.
- Interpolación en z no siempre suave — hay zonas de baja densidad.

Próximos pasos:

- Ampliar benchmark: más grupos, más genes (500-2000), estructura irregular.
- Entrenar con datos reales — el pipeline no necesita cambios arquitectónicos.
- Evaluar downstream: ¿clasificadores en sintéticos funcionan en datos reales?

NÚMEROS CLAVE			
● MAE_rA N=1000	0.0137	● 2g condicional	98.5%
● KNN ratio	7.8×	● Error modelo	≈ 0 (límite estadístico)

» PARA LA EXPOSICIÓN

"El modelo resuelve perfectamente su problema. El siguiente paso es ampliar el problema — más genes, más grupos, datos reales. La arquitectura ya está. Lo que falta es el benchmark."