

TDVAE

VAE de datasets
completos

800 épocas · 7000 datasets
50 genes · LATENT_DIM=64

Un modelo generativo donde cada punto
del espacio latente representa un dataset
entero, no una muestra individual.

0.010

MAE_rA N=1000

98.5%

2-grupos cond.


7.8×

KNN ratio

El problema: generadores fila a fila


Los generadores actuales no controlan la estructura global de correlaciones

CTGAN / TVAE / DDPM



❑ *Estructura global emerge por accidente*


TDVAE (este modelo)



❑ *Control explícito de correlaciones*




Arquitectura TDVAE

Encoder · Decoder con ResBlocks · Copula empírica · Predictor auxiliar



Datos de entrenamiento

7000 datasets RNA-seq sintéticos · 200 muestras × 50 genes · 2 grupos



Generación: Gaussian Copula · NegBinomial marginals · SHUFFLE_FRAC = 0.20 · ruido gaussiano en Σ

Resultados — 1400 datasets test nunca vistos

0.0137

MAE_rA
N=1000

98.5%

2-grupos
condicional N=200

0.9995

Predictor r
z $\square$ correlaciones

7.8×

KNN ratio
vecinos vs aleatorio

75%



% datasets
MAE < 0.02

Rendimiento relativo por métrica



Prueba 1 — Fidelidad y preservación de estructura

MAE en correlaciones · Estructura 2-grupos condicional








Condiciona = evalúa solo los 1091/1400 datasets donde el original también tiene estructura 2-grupos

Prueba 4 — El espacio latente organiza datasets por estructura



Cada punto = un dataset · Moverse en el mapa = cambiar la estructura de correlación

Mapa del espacio latente (1400 datasets)
color = cross_corr



Prueba 4d — Interpolación en el espacio latente

Línea recta en z produce transición continua de la estructura de correlación




Distribución del error — 1400 datasets test

42% con $MAE < 0.01$ · 75% con $MAE < 0.02$ · 99.9% con $MAE < 0.05$



¿Qué se ve a cada nivel de error?




Prueba 6 — El error del modelo es estadísticamente indistinguible de cero

MAE_rA sigue la curva $1/\sqrt{N}$ — todo el error visible es ruido de muestreo de la Copula


MAE sigue exactamente $1/\sqrt{N}$

□ error del modelo ≈ 0



$N=200$: MAE=0.0207 SE=0.0712 · $N=1000$: MAE=0.0143 SE=0.0317 · $N=2000$: MAE=0.0128 ($\approx$ suelo estadístico)

Desglose: modelo vs ruido de muestreo



Conclusiones

TDVAE · VAE de datasets completos · PoC sobre 50 genes sintéticos

- MAE_rA = 0.010 con N=1000 — prácticamente el límite estadístico
- Estructura 2-grupos preservada en el 98.5% de los casos (condicional, N=200)
- Predictor $r = 0.9995$ · PC1 $\square$ cross · PC2 $\square$ rA · PC3 $\square$ rB
- KNN ratio 7.8×: la distancia en z predice similitud estructural
- 75% de datasets con MAE < 0.02 · 99.9% con MAE < 0.05

□ Entrenado en 50 genes sintéticos — no evaluado en datos reales aún

□ Siguiendo paso: más grupos, más genes, datos reales (TCGA / GEO)